Case Study #4

Cardiovascular Disease Prediction

Projeto segundo a metodologia CRISP-DM

Business Intelligence Analytics — Ferramentas e Aplicações

Grupo 3
Giulia Jacobina
João Coelho
Larissa Tostes

2026

Índice

Resumo..... 3
1. Business Understanding..... 3
    1.1 Contexto e problema de negócio..... 3
    1.2 Objetivos..... 3
    1.3 Questões de pesquisa..... 3
    1.4 Análise SWOT..... 4
2. Data Understanding..... 4
    2.1 O conjunto de dados..... 4
    2.2 Exploração..... 4
    2.3 Avaliação da qualidade dos dados..... 4
3. Data Preparation..... 5
    3.1 Engenharia de variáveis..... 5
    3.2 Limpeza..... 5
    3.3 Codificação e dataset final..... 5
4. Modeling..... 6
5. Evaluation..... 6
    5.1 Importância das variáveis..... 6
    5.2 Respostas às questões de pesquisa..... 6
6. Deployment..... 7
    6.1 Modelo recomendado e forma de uso..... 7
    6.2 Arquitetura proposta..... 7
    6.3 Implementação prática em Amazon SageMaker..... 7
    6.4 Monitorização e custos..... 8
    6.5 Limitações e trabalho futuro..... 8
    6.6 Considerações éticas..... 8
7. Conclusão..... 9
8. Referências..... 10
9. Contribuição de cada elemento..... 10

Resumo

Este relatório descreve um projeto de previsão de doença cardiovascular desenvolvido segundo a metodologia CRISP-DM. Partimos de um conjunto de dados público com cerca de 70.000 registos de pacientes e quisemos perceber duas coisas: que características clínicas e demográficas se associam à presença da doença, e se esses dados chegam para sinalizar o risco com utilidade prática. Embora o problema seja contextualizado com indicadores portugueses, o dataset utilizado é público e não representa especificamente Portugal.

Treinámos quatro modelos de classificação e comparámos o seu desempenho, dando atenção especial ao recall, porque num contexto de saúde não detetar um doente em risco é mais grave do que gerar um alarme falso. Em termos de AUC, os melhores resultados foram obtidos pela Regressão Logística, Decision Tree e XGBoost, com valores próximos de 0,79, enquanto o Random Forest se destacou pelo maior recall. A fase de deployment foi levada até ao fim: o modelo foi treinado, alojado e testado no Amazon SageMaker, com endpoint em tempo real e previsões em lote.

1. Business Understanding

1.1 Contexto e problema de negócio

As doenças cardiovasculares são uma das principais causas de morte em Portugal. Segundo o INE, representaram 25,4% dos óbitos registados em 2024, estando também associadas a custos hospitalares elevados. Estes dados foram usados para contextualizar a relevância do problema num cenário nacional. No entanto, importa esclarecer que o dataset utilizado neste projeto é um conjunto de dados público disponível no Kaggle e não corresponde especificamente à população portuguesa. Assim, os resultados devem ser interpretados como uma prova de conceito aplicada à previsão de risco cardiovascular, e não como uma análise epidemiológica representativa de Portugal.

O problema que abordamos é, no fundo, este: as características de um paciente permitem sinalizar com antecedência um risco acrescido de doença cardiovascular? Se sim, uma abordagem orientada por dados pode ajudar a identificar perfis de risco mais cedo e apoiar decisões preventivas, desde que os resultados sejam interpretados com cautela e validados no contexto populacional onde venham a ser aplicados.

1.2 Objetivos

Os objetivos de negócio do projeto são:

- Apoiar a prevenção através da identificação de fatores de risco relevantes;
- Contribuir para decisões clínicas mais informadas;

- Sinalizar grupos de pacientes com maior probabilidade de doença cardiovascular;
- Reduzir custos associados a diagnósticos tardios e internamentos;
- Apoiar uma utilização mais eficiente dos recursos de saúde.

1.3 Questões de pesquisa

A análise foi guiada por quatro questões:

1. Que variáveis estão mais associadas à presença de doença cardiovascular?
2. Como diferem a idade, o peso e a pressão arterial entre pacientes com e sem a doença?
3. Os níveis de colesterol e glicose mostram relação com a doença?
4. A prática de atividade física está associada a menor prevalência da doença no dataset?

1.4 Análise SWOT

Pontos fortes: o problema tem valor preventivo claro e o dataset, com cerca de 70.000 registos, permite uma análise consistente. A deteção precoce pode reduzir internamentos e tratamentos mais complexos.

Pontos fracos: a qualidade dos dados é desigual (há valores extremos e erros de registo), faltam variáveis clínicas relevantes como histórico familiar ou medicação, e há o risco de simplificar uma doença que é multifatorial.

Oportunidades: integração em plataformas de medicina preventiva e telemedicina, e ligação a programas de rastreio. Ameaças: baixa adoção pelos profissionais, exigências de proteção de dados de saúde, e a concorrência de soluções já estabelecidas.

2. Data Understanding

2.1 O conjunto de dados

Usámos o Cardiovascular Disease Dataset, disponível no Kaggle, com 70.000 observações e 13 variáveis (incluindo o identificador e a variável alvo). Este dataset é utilizado como base pública para modelação e não deve ser interpretado como uma amostra representativa da população portuguesa. As variáveis dividem-se em demográficas (idade, género), físicas (altura, peso), clínicas (pressão arterial sistólica e diastólica, colesterol, glicose) e comportamentais (tabaco, álcool, atividade física). A variável alvo, cardio, indica a ausência (0) ou presença (1) de doença cardiovascular.

2.2 Exploração

A variável alvo está equilibrada, com cerca de 50% de casos em cada classe, o que evita problemas de desbalanceamento no alvo. Entre as variáveis numéricas, a única correlação assinalável é entre altura e peso (r próximo de 0,29); as restantes comportam-se de forma praticamente independente. As variáveis comportamentais têm classes muito desequilibradas (poucos fumadores e poucos consumidores de álcool), por isso qualquer leitura sobre elas exige cautela. Em termos gerais, os pacientes com a doença tendem a ter idade, IMC e pressão arterial mais elevados.

2.3 Avaliação da qualidade dos dados

Não havia valores em falta nem registos duplicados, e as categorias estavam todas dentro do esperado. Os problemas concentravam-se em valores fisicamente impossíveis, sobretudo na pressão arterial. O quadro seguinte resume o que foi detetado nesta fase.

Variável	Intervalo plausível	Registos afetados	Observação
height (altura)	120 – 220 cm	53	Altura implausível para um adulto
weight (peso)	30 – 200 kg	7	Peso incompatível com a população adulta
ap_hi (sistólica)	70 – 250 mmHg	229	Fora do intervalo fisiológico
ap_lo (diastólica)	40 – 150 mmHg	1.034	Sobretudo erros de entrada de dados
ap_hi ≤ ap_lo	lei fisiológica	1.236	Fisicamente impossível

Estes problemas foram identificados aqui e tratados na fase seguinte.

3. Data Preparation

A preparação dos dados resumiu-se a três operações: criar variáveis mais úteis, limpar registos incoerentes e organizar o dataset final.

3.1 Engenharia de variáveis

Criámos três variáveis novas. A idade passou a estar em anos (age_years), em vez de dias, o que a torna legível. Calculámos o índice de massa corporal (bmi) a partir do peso e da altura, juntando duas medidas numa só com sentido clínico. E acrescentámos a pressão de pulso (pulse_pressure), a diferença entre a sistólica e a diastólica, que é um indicador cardiovascular conhecido.

3.2 Limpeza

Aplicámos filtros de plausibilidade: altura entre 120 e 220 cm, peso entre 30 e 200 kg, sistólica entre 70 e 250, diastólica entre 40 e 150, e a exigência de a sistólica ser sempre superior à diastólica. O dataset passou de 70.000 para 68.610 registos, ou seja, foram removidos 1.390 registos, menos de 2% do total (1,99%). A intenção não foi eliminar a variação real entre pacientes, mas apenas os valores impossíveis. As

verificações repetidas depois da limpeza confirmaram que todos os problemas anteriores ficaram a zero.

3.3 Codificação e dataset final

Codificámos o género com one-hot encoding e removemos a variável id, que serve apenas de identificador e não tem valor clínico. A variável cardio manteve-se como alvo. O dataset final ficou com 68.610 registos e 15 features, pronto para a modelação. Este mesmo dataset preparado foi depois exportado para reutilização direta no SageMaker, o que garante que o modelo em cloud recebe exatamente os dados tratados nesta fase.

4. Modeling

Dividimos o dataset em 80% para treino e 20% para teste (54.888 e 13.722 registos), com estratificação pela variável alvo para manter a proporção das classes nos dois conjuntos. Aplicámos normalização com o StandardScaler: é necessária para a regressão logística e indiferente para os modelos baseados em árvores, mas usámo-la em todos por consistência.

Treinámos quatro modelos de classificação binária: uma Logistic Regression como baseline, uma Decision Tree (profundidade máxima 5), um Random Forest (100 árvores) e um XGBoost (100 iterações). A escolha cobre desde um modelo linear simples e interpretável até ensembles com maior capacidade preditiva.

5. Evaluation

Comparámos os modelos por accuracy, precision, recall, F1 e AUC-ROC, e complementámos a leitura com as matrizes de confusão e as curvas ROC. Os resultados estão no quadro abaixo.

Modelo	Accuracy	Precision	Recall	F1	AUC
Logistic Regression	0,73	0,75	0,67	0,71	0,79
Decision Tree	0,73	0,75	0,66	0,71	0,79
Random Forest	0,72	0,72	0,70	0,71	0,77
XGBoost	0,73	0,74	0,69	0,72	0,79

Os quatro modelos ficaram muito próximos, o que mostra que as variáveis disponíveis têm capacidade preditiva moderada, mas também limitações. A Regressão Logística, a Decision Tree e o XGBoost lideraram em AUC (0,79), enquanto o XGBoost apresentou o melhor F1. No entanto, a escolha do modelo não deve basear-se apenas na accuracy ou na AUC: num problema de saúde, o recall assume especial importância, pois mede a capacidade de identificar corretamente os pacientes que têm a doença. Nesse critério, o Random Forest destacou-se com recall de 0,70, reduzindo o risco de falsos negativos face aos restantes modelos.

5.1 Importância das variáveis

A análise de importância no Random Forest e no XGBoost aponta para os mesmos preditores no topo: a pressão arterial sistólica (ap_hi), a idade (age_years) e o IMC (bmi). É um resultado coerente com o que a literatura clínica já indica.

5.2 Respostas às questões de pesquisa

Q1. As variáveis mais associadas à doença são a pressão sistólica, a idade e o IMC.

Q2. Os pacientes com doença apresentam, em média, idade, peso e pressão arterial mais altos, sendo a pressão arterial a que mostra maior diferença.

Q3. Sim. Níveis mais altos de colesterol e glicose acompanham maior prevalência da doença, embora com um efeito menos forte do que o da pressão arterial.

Q4. Os dados sugerem uma associação modesta entre atividade física e menor prevalência, mas com menor poder preditivo do que as variáveis clínicas.

6. Deployment

6.1 Modelo recomendado e forma de uso

Os modelos recomendados são o Random Forest e o XGBoost: o primeiro pelo melhor recall, métrica prioritária para reduzir falsos negativos, e o segundo pelo melhor equilíbrio global entre F1, AUC e facilidade de implementação no Amazon SageMaker. Apesar de o Random Forest ter apresentado o melhor recall, o XGBoost foi escolhido para o deployment por estar disponível como algoritmo integrado na plataforma, facilitando o treino, o alojamento do modelo e a inferência em cloud. Como as diferenças de desempenho entre os modelos foram reduzidas, esta escolha é adequada para uma prova de conceito.

O destinatário é o profissional de saúde, médico ou enfermeiro, em contexto de prevenção. A partir dos dados de um paciente, o modelo devolve uma probabilidade de risco que serve para sinalizar quem encaminhar para exames adicionais e ajudar a priorizar consultas. É um apoio à decisão, não um substituto do diagnóstico.

6.2 Arquitetura proposta

A arquitetura disponibiliza o modelo como uma API através de um endpoint do Amazon SageMaker. O fluxo é direto: o profissional introduz os dados do paciente numa aplicação clínica, os dados seguem para o endpoint, o modelo devolve a probabilidade de risco e o sistema apresenta-a ao profissional, ficando a decisão final do lado clínico. Além da inferência em tempo real, a solução considera também previsões em lote através de Batch Transform.

6.3 Implementação prática em Amazon SageMaker

A proposta de arquitetura foi concretizada num fluxo de deployment completo no SageMaker, em vez de ficar apenas no plano teórico. O processo seguiu os seguintes passos:

- Exportação do dataset final da fase de Data Preparation, para garantir que o modelo em cloud usa exatamente os mesmos dados limpos e codificados;
- Criação da sessão SageMaker e obtenção do IAM Role (com get_execution_role no SageMaker Studio);
- Divisão dos dados e gravação dos ficheiros CSV no formato exigido pelo XGBoost integrado: variável alvo na primeira coluna e sem cabeçalho;
- Upload dos ficheiros de treino, validação e teste para o Amazon S3;
- Treino do modelo com o XGBoost built-in do SageMaker, com o objetivo binary:logistic adequado à classificação binária;
- Criação de um endpoint em tempo real (instância ml.m5.large) e teste de uma inferência individual, convertendo a probabilidade em classe com um threshold de 0,5;
- Eliminação do endpoint após o teste, para evitar custos desnecessários;
- Execução de um Batch Transform sobre todo o conjunto de teste, com leitura das previsões a partir do S3 e cálculo das métricas de classificação.

Foram guardadas evidências de cada etapa (training job concluído, endpoint criado, output da inferência em tempo real, eliminação do endpoint e resultados do Batch Transform), que documentam que o modelo não ficou apenas treinado localmente: foi treinado, alojado e testado numa infraestrutura cloud.

6.4 Monitorização e custos

Um modelo em produção precisa de acompanhamento: vigiar a degradação do desempenho ao longo do tempo, detetar alterações no perfil dos dados e prever re-treinos periódicos, sempre com atenção ao recall. Em termos de custo, o endpoint é cobrado por hora, por isso foi apagado após os testes; o Batch Transform desliga a instância automaticamente.

6.5 Limitações e trabalho futuro

Algumas variáveis (tabaco, álcool, atividade física) são auto-reportadas, o que introduz ruído. Não aplicámos validação cruzada nem otimização de hiperparâmetros, e faltam variáveis clínicas que pesariam no risco, como o histórico familiar ou a medicação.

Em trabalho futuro, faria sentido aplicar validação cruzada k-fold para uma estimativa mais robusta, otimizar os hiperparâmetros com GridSearchCV ou RandomizedSearchCV, usar SHAP para explicar previsões individuais, e testar o modelo noutras populações para avaliar a generalização.

6.6 Considerações éticas

Os dados de saúde são uma categoria especial ao abrigo do RGPD, o que exige consentimento explícito e medidas de segurança reforçadas. O risco mais crítico aqui é o falso negativo, ou seja, classificar como saudável quem tem a doença, porque atrasa o tratamento; o threshold de decisão deve ser calibrado a pensar nisso. O modelo deve ser explicável, e técnicas como o SHAP ajudam a justificar cada previsão. A responsabilidade pela decisão clínica é sempre do profissional de saúde. Vale ainda notar o desequilíbrio de género do dataset, que pode afetar o desempenho em diferentes grupos.

7. Conclusão

O projeto percorreu as seis fases do CRISP-DM, desde a compreensão do problema e dos dados até à preparação, modelação, avaliação e deployment. A versão final não ficou limitada ao ambiente de notebook: o modelo foi treinado, alojado e testado no Amazon SageMaker, permitindo inferência em tempo real através de um endpoint e previsões em lote através de Batch Transform.

Os quatro modelos avaliados apresentaram desempenhos relativamente próximos, com valores de AUC em torno de 0,79 e accuracy próxima de 73%. Estes resultados são razoáveis, sobretudo considerando que foram utilizadas variáveis de fácil obtenção. Ainda assim, é importante reconhecer as limitações do modelo: cerca de uma em cada quatro previsões pode estar incorreta, sendo os falsos negativos o erro mais sensível neste contexto, uma vez que correspondem a pacientes com doença cardiovascular classificados como saudáveis. Por esse motivo, a escolha do modelo deu especial importância ao recall, procurando reduzir este tipo de erro.

A principal mais-valia desta versão foi concluir o ciclo do projeto com deployment em cloud. Demonstrar que o modelo pode ser disponibilizado numa infraestrutura como o Amazon SageMaker, receber novos dados e devolver uma probabilidade de risco aproxima o trabalho de um cenário real de aplicação. No entanto, o sistema deve ser entendido como uma prova de conceito. Como o dataset não representa especificamente Portugal, os resultados não devem ser generalizados diretamente para a população portuguesa sem validação adicional com dados nacionais. Num contexto clínico real, seriam necessárias validações adicionais, mais variáveis clínicas, calibração do threshold e testes com dados externos.

Assim, a previsão produzida pelo modelo deve ser usada como apoio à sinalização e priorização de casos, nunca como substituto da decisão médica. A interpretação final deve permanecer sempre sob responsabilidade de um profissional de saúde.

8. Referências

Instituto Nacional de Estatística (INE). (2026). Estatísticas de óbitos por causas de morte em Portugal, 2024.

Ulianova, S. (2019). Cardiovascular Disease Dataset. Kaggle.

Amazon Web Services. (2026). Amazon SageMaker Developer Guide: XGBoost algorithm and real-time endpoints.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.

União Europeia. (2016). Regulamento (UE) 2016/679 do Parlamento Europeu e do Conselho, de 27 de abril de 2016 (Regulamento Geral sobre a Proteção de Dados - RGPD).

Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems.

9. Contribuição de cada elemento

A distribuição do trabalho foi equilibrada entre os três elementos do grupo, correspondendo a 33,3% para cada elemento.

Giulia Jacobina — 33,3%: Contribuiu para a proposta do projeto, Business Understanding, Data Understanding, relatório final, notebook e apresentação.

João Coelho — 33,3%: Contribuiu para a proposta do projeto, Data Understanding, Data Preparation, relatório final, notebook e apresentação.

Larissa Tostes — 33,3%: Contribuiu para a proposta do projeto, Modeling, Evaluation, relatório final, notebook e apresentação.